



基于 Apache Spark 的分布式计算实 验

典型分布式（云）技术及系统·课程实践

汇报人：XXX | 学号：202X0000 | 202X-XX-XX

目录 / Agenda

1 选题背景与目标

3 系统架构与部署

5 算法一：PageRank 实现

7 分布式特性分析

2 Apache Spark 简介

4 部署验证展示

6 算法二：TF-IDF 分析

8 总结与展望

选题背景与目标

- 🗄️ **数据爆炸**：单机计算能力已达瓶颈
- 👥 **集群协作**：多节点并行处理海量数据
- 🎯 **实验目标**：搭建分布式集群环境
- 🔧 **核心验证**：复杂算法在分布式下的性能

验证分布式计算的“多节点协同”能力



| Apache Spark 简介

- ⚡ 极速性能：比 MapReduce 快 10-100 倍
- 💾 内存计算：减少磁盘 I/O 开销
- 📦 核心抽象：RDD (弹性分布式数据集)
- </> 多语言：支持 Python, Java, Scala, R

Spark 核心概念



RDD

不可变、可分区、可并行操作的数据集合，支持血统容错。



Transformation

惰性操作（如 map, filter），仅在 Action 触发时执行。



Action

触发实际计算（如 collect, count），将结果返回驱动程序。

| 系统架构设计

- 👑 1 Master : 任务调度与资源管理
- 🤖 2 Workers : 2C / 1G 任务执行单元
- 📡 虚拟网络 : Docker Network 通信
- 📦 容器化 : 独立 IP , 环境快速复现

环境部署方案

Docker Compose 部署

基础镜像：Ubuntu 22.04 + OpenJDK 17

版本：Spark 3.5.8

优势：一键部署，环境一致性 100%

`./start-cluster.sh` 一键启动

```
services:
  spark-master:
    image: spark-local:3.5.8
    command: start-master.sh
  spark-worker-1:
    image: spark-local:3.5.8
    command: start-worker.sh
    # 连接到 master:7077
```


部署验证 (Web UI)

✓ 注册状态：2 Workers 已激活

♥ 状态监测：节点状态显示 ALIVE

☰ 总资源：4 Cores / 2 GB RAM

实时监控地址：*localhost:8080*

▼ Active Jobs (1)

Page: 11 Pages. Jump to 1. Show 100 items in a page. Go

Job Id ▼	Description	Submitted	Duration	Stages: Succeeded/Total	Tasks (for all stages): Succeeded/Total
7	count at <console>:26 count at <console>:26 (kill)	2019/08/10 17:50:13	17 s	0/2	0/5 (4 running)

▼ Completed Jobs (7)

Page: 11 Pages. Jump to 1. Show 100 items in a page. Go

Job Id ▼	Description	Submitted	Duration	Stages: Succeeded/Total	Tasks (for all stages): Succeeded/Total
6	show at <console>:26 show at <console>:26	2019/08/10 17:49:30	0.4 s	1/1	1/1
5	show at <console>:28 show at <console>:28	2019/08/10 17:48:32	0.8 s	3/3	9/9
4	show at <console>:28 show at <console>:28	2019/08/10 17:47:40	2 s	3/3	9/9

算法一：PageRank 原理

核心公式

$$PR(A) = \frac{1-d}{N} + d \cdot \sum \frac{PR(T_i)}{C(T_i)}$$

$d = 0.85$ (阻尼系数)

逻辑说明

1. 重要页面指向你，你就重要。
2. 权重随迭代次数逐渐收敛。
3. 模拟随机点击网页的行为。

PageRank 分布式实现



PageRank 实验结果

测试规模：20 节点 / 84 边 | 迭代 10 次 | 耗时 8.95s

排名	节点名称	PageRank 权重	状态
1	G	0.06781	Top 1
2	I	0.06373	-
3	D	0.06157	-
4	E	0.05980	-
5	R	0.05642	-

算法二：TF-IDF 原理

计算公式

$$\text{TF-IDF} = \text{TF}(t, d) \times \log\left(\frac{N}{\text{df}(t)}\right)$$

寻找对当前文档最具区分度的词项。

应用场景

1. 关键词提取：自动提取核心概念。
2. 文本检索：按相关性排序。
3. 相似度：通过向量夹角计算相似。

TF-IDF 分布式流水线



TF-IDF 文本相似度结果

数据：6 篇代表性学术文档 | 特征维度：1024 | 耗时 11.39s

排名	文档 A	文档 B	相似度分数
1	machine_learning	neural_networks	0.1854
2	big_data	spark_framework	0.1665
3	cloud_computing	big_data	0.0892
4	neural_networks	spark_framework	0.0802
5	machine_learning	big_data	0.0787

任务运行监控分析

🕒 动态分配：任务被划分为多个 Stages

📊 资源占用：Worker 节点满载运行

🔄 DAG 视角：优化了 RDD 依赖关系

验证：并行度与 Worker 数量呈正相关

▼ Active Jobs (1)

Page: 11 Pages. Jump to 1. Show 100 items in a page. Go

Job Id ▼	Description	Submitted	Duration	Stages: Succeeded/Total	Tasks (for all stages): Succeeded/Total
7	count at <console>:26 count at <console>:26 (kill)	2019/08/10 17:50:13	17 s	0/2	0/5 (4 running)

▼ Completed Jobs (7)

Page: 11 Pages. Jump to 1. Show 100 items in a page. Go

Job Id ▼	Description	Submitted	Duration	Stages: Succeeded/Total	Tasks (for all stages): Succeeded/Total
6	show at <console>:26 show at <console>:26	2019/08/10 17:49:30	0.4 s	1/1	1/1
5	show at <console>:28 show at <console>:28	2019/08/10 17:48:32	0.8 s	3/3	9/9
4	show at <console>:28 show at <console>:28	2019/08/10 17:47:40	2 s	3/3	9/9

分布式特性深度分析

- 数据交换

分布式特性	实现机制	实验验证表现
并行处理	数据自动切分 Partition	多个 Worker 同时高负荷运转
任务调度	Master 动态分配 Task	任务均匀分布，无明显长尾效应
血统容错	RDD Lineage 信息保存	即便单点失败，可根据血统重算
Shuffle 操作	在 PageRank 聚合阶段存在 IO 开销	

实验总结与收获

- ✓ 环境：成功搭建 Docker 化分布式计算平台
- ✓ 算法：验证了 PageRank 与 TF-IDF 在集群下的正确性
- ✓ 理解：深刻掌握了 Master-Worker 架构与 RDD 编程模型
- ✓ 体悟：认知到 Shuffle 开销是分布式计算的主要瓶颈

未来工作展望



规模扩展

增加至 10+ Workers 测试加速比曲线。



超大规模数据

使用全量 Wikipedia 语料测试 TF-IDF 性能。



实时演进

引入 Spark Streaming 进行实时流计算实验。

THANK YOU

Q&A | 敬请批评指正

主要参考文献：

1. Zaharia M, et al. "Spark: Cluster Computing with Working Sets." 2010.
2. Page L, et al. "The PageRank Citation Ranking." 1999.
3. Apache Spark Official Docs: spark.apache.org

Image Sources



https://images.seeklogo.com/logo-png/61/1/apache-spark-logo-png_seeklogo-616735.png
Source: seeklogo.com




https://media.istockphoto.com/id/2216010815/vector/centralized-logistics-and-distribution-hub-isometric-illustration.jpg?s=612x612&w=0&k=20&c=NJqTtLVuqzFITcoxZ_GV-NcgbXwy3yyDcMqQqsjNICw=
Source: www.istockphoto.com



Thumbnail
for https://nexocode.com/cdn-cgi/image/width=600,quality=75/images/apache_spark_ecosystem.webp
Source: nexocode.com

nexocode.com



<https://krijnvanrooijen.nl/assets/graphics/2025-04-20-local-spark-cluster-devcontainer/design.drawio.png>
Source: krijnvanrooijen.nl



<https://spark.apache.org/docs/latest/img/AllJobsPageDetail3.png>
Source: spark.apache.org